

## 18 | 散列表（上）：Word文档中的单词拼写检查功能是如何实现的？

2018-10-31 王争

数据结构与算法之美

[进入课程 >](#)



讲述：修阳

时长 13:39 大小 6.26M



Word 这种文本编辑器你平时应该经常用吧，那你有没有留意过它的拼写检查功能呢？一旦我们在 Word 里输入一个错误的英文单词，它就会用标红的方式提示“拼写错误”。

**Word 的这个单词拼写检查功能，虽然很小但却非常实用。你有没有想过，这个功能是如何实现的呢？**

其实啊，一点儿都不难。只要你学完今天的内容，**散列表**（Hash Table）。你就能像微软 Office 的工程师一样，轻松实现这个功能。

### 散列思想

散列表的英文叫 “Hash Table”，我们平时也叫它 “哈希表” 或者 “Hash 表”，你一定也经常听过它，我在前面的文章里，也不止一次提到过，但是你是不是真的理解这种数据结构呢？

**散列表用的是数组支持按照下标随机访问数据的特性，所以散列表其实就是数组的一种扩展，由数组演化而来。可以说，如果没有数组，就没有散列表。**

我用一个例子来解释一下。假如我们有 89 名选手参加学校运动会。为了方便记录成绩，每个选手胸前都会贴上自己的参赛号码。这 89 名选手的编号依次是 1 到 89。现在我们希望编程实现这样一个功能，通过编号快速找到对应的选手信息。你会怎么做呢？

我们可以把这 89 名选手的信息放在数组里。编号为 1 的选手，我们放到数组中下标为 1 的位置；编号为 2 的选手，我们放到数组中下标为 2 的位置。以此类推，编号为  $k$  的选手放到数组中下标为  $k$  的位置。

因为参赛编号跟数组下标一一对应，当我们需要查询参赛编号为  $x$  的选手的时候，我们只需要将下标为  $x$  的数组元素取出来就可以了，时间复杂度就是  $O(1)$ 。这样按照编号查找选手信息，效率是不是很高？

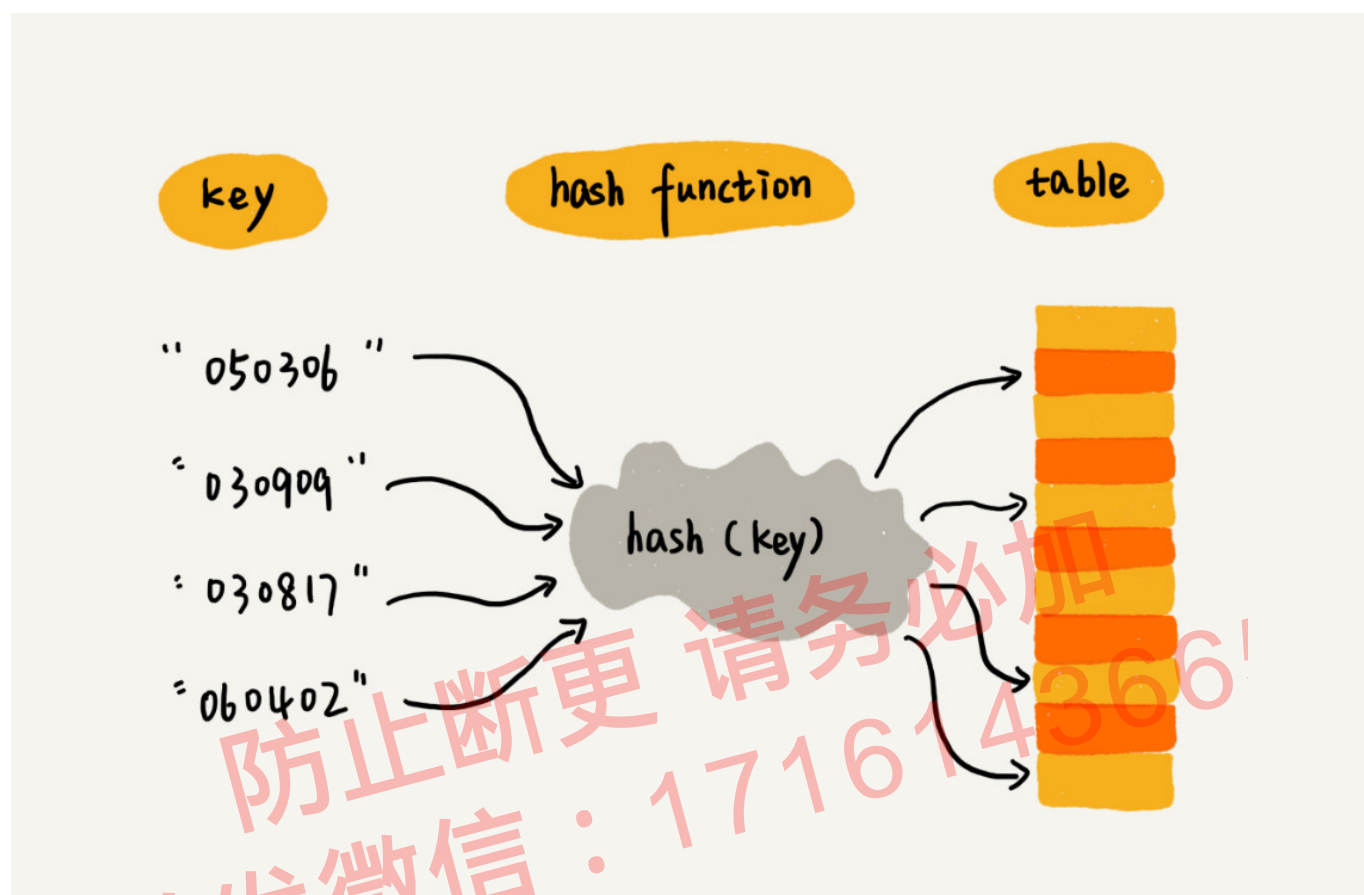
实际上，这个例子已经用到了散列的思想。在这个例子里，参赛编号是自然数，并且与数组的下标形成一一映射，所以利用数组支持根据下标随机访问的时候，时间复杂度是  $O(1)$  这一特性，就可以实现快速查找编号对应的选手信息。

你可能要说了，这个例子中蕴含的散列思想还不够明显，那我来改造一下这个例子。

假设校长说，参赛编号不能设置得这么简单，要加上年级、班级这些更详细的信息，所以我们把编号的规则稍微修改了一下，用 6 位数字来表示。比如 051167，其中，前两位 05 表示年级，中间两位 11 表示班级，最后两位还是原来的编号 1 到 89。这个时候我们该如何存储选手信息，才能够支持通过编号来快速查找选手信息呢？

思路还是跟前面类似。尽管我们不能直接把编号作为数组下标，但我们可以截取参赛编号的后两位作为数组下标，来存取选手信息数据。当通过参赛编号查询选手信息的时候，我们用同样的方法，取参赛编号的后两位，作为数组下标，来读取数组中的数据。

这就是典型的散列思想。其中，参赛选手的编号我们叫作**键**（key）或者**关键字**。我们用它来标识一个选手。我们把参赛编号转化为数组下标的映射方法就叫作**散列函数**（或“Hash 函数”“哈希函数”），而散列函数计算得到的值就叫作**散列值**（或“Hash 值”“哈希值”）。



通过这个例子，我们可以总结出这样的规律：散列表用的就是数组支持按照下标随机访问的时候，时间复杂度是  $O(1)$  的特性。我们通过散列函数把元素的键值映射为下标，然后将数据存储在数组中对应下标的位置。当我们按照键值查询元素时，我们用同样的散列函数，将键值转化数组下标，从对应的数组下标的位置取数据。

## 散列函数

从上面的例子我们可以看到，散列函数在散列表中起着非常关键的作用。现在我们就来学习下散列函数。

散列函数，顾名思义，它是一个函数。我们可以把它定义成 **hash(key)**，其中 key 表示元素的键值，hash(key) 的值表示经过散列函数计算得到的散列值。

那第一个例子中，编号就是数组下标，所以 hash(key) 就等于 key。改造后的例子，写成散列函数稍微有点复杂。我用伪代码将它写成函数就是下面这样：

```
1 int hash(String key) {  
2     // 获取后两位字符  
3     string lastTwoChars = key.substr(length-2, length);  
4     // 将后两位字符转换为整数  
5     int hashValue = convert lastTwoChars to int-type;  
6     return hashValue;  
7 }
```

刚刚举的学校运动会的例子，散列函数比较简单，也比较容易想到。但是，如果参赛选手的编号是随机生成的 6 位数字，又或者用的是 a 到 z 之间的字符串，**该如何构造散列函数呢？我总结了三点散列函数设计的基本要求：**

1. 散列函数计算得到的散列值是一个非负整数；
2. 如果  $key1 = key2$ ，那  $hash(key1) == hash(key2)$ ；
3. 如果  $key1 \neq key2$ ，那  $hash(key1) \neq hash(key2)$ 。

我来解释一下这三点。其中，第一点理解起来应该没有任何问题。因为数组下标是从 0 开始的，所以散列函数生成的散列值也要是非负整数。第二点也很好理解。相同的 key，经过散列函数得到的散列值也应该是相同的。

第三点理解起来可能会有问题，我着重说一下。这个要求看起来合情合理，但是在真实的情况下，要想找到一个不同的 key 对应的散列值都不一样的散列函数，几乎是不可能的。即便像业界著名的 [MD5](#)、[SHA](#)、[CRC](#) 等哈希算法，也无法完全避免这种**散列冲突**。而且，因为数组的存储空间有限，也会加大散列冲突的概率。

所以我们几乎无法找到一个完美的无冲突的散列函数，即便能找到，付出的时间成本、计算成本也是很大的，所以针对散列冲突问题，我们需要通过其他途径来解决。

## 散列冲突


再好的散列函数也无法避免散列冲突。那究竟该如何解决散列冲突问题呢？我们常用的散列冲突解决方法有两类，开放寻址法（open addressing）和链表法（chaining）。

### 1. 开放寻址法

开放寻址法的核心思想是，如果出现了散列冲突，我们就重新探测一个空闲位置，将其插入。那如何重新探测新的位置呢？我先讲一个比较简单的探测方法，**线性探测**（Linear Probing）。

当我们往散列表中插入数据时，如果某个数据经过散列函数散列之后，存储位置已经被占用了，我们就从当前位置开始，依次往后查找，看是否有空闲位置，直到找到为止。


我说的可能比较抽象，我举一个例子具体给你说明一下。这里面黄色的色块表示空闲位置，橙色的色块表示已经存储了数据。




从图中可以看出，散列表的大小为 10，在元素 x 插入散列表之前，已经 6 个元素插入到散列表中。x 经过 Hash 算法之后，被散列到位置下标为 7 的位置，但是这个位置已经有数据了，所以就产生了冲突。于是我们就顺序地往后一个一个找，看有没有空闲的位置，遍历到尾部都没有找到空闲的位置，于是我们再从表头开始找，直到找到空闲位置 2，于是将其插入到这个位置。

在散列表中查找元素的过程有点儿类似插入过程。我们通过散列函数求出要查找元素的键值对应的散列值，然后比较数组中下标为散列值的元素和要查找的元素。如果相等，则说明就是我们要找的元素；否则就顺序往后依次查找。如果遍历到数组中的空闲位置，还没有找到，就说明要查找的元素并没有在散列表中。

y 在散列表中



y 不在散列表中

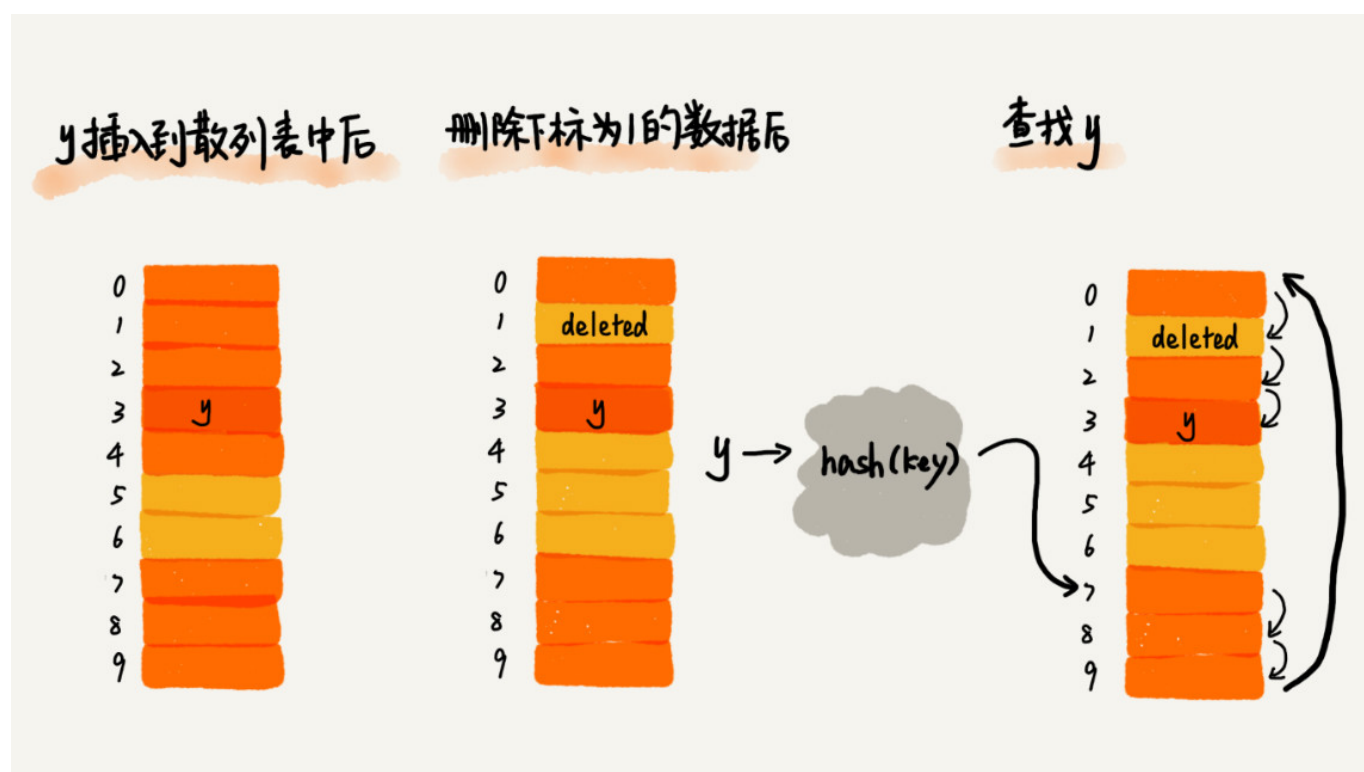


散列表跟数组一样，不仅支持插入、查找操作，还支持删除操作。对于使用线性探测法解决冲突的散列表，删除操作稍微有些特别。我们不能单纯地把要删除的元素设置为空。这是为什么呢？



还记得我们刚讲的查找操作吗？在查找的时候，一旦我们通过线性探测方法，找到一个空闲位置，我们就可以认定散列表中不存在这个数据。但是，如果这个空闲位置是我们后来删除的，就会导致原来的查找算法失效。本来存在的数据，会被认定为不存在。这个问题如何解决呢？

我们可以将删除的元素，特殊标记为 `deleted`。当线性探测查找的时候，遇到标记为 `deleted` 的空间，并不是停下来，而是继续往下探测。



你可能已经发现了，线性探测法其实存在很大问题。当散列表中插入的数据越来越多时，散列冲突发生的可能性就会越来越大，空闲位置会越来越少，线性探测的时间就会越来越久。极端情况下，我们可能需要探测整个散列表，所以最坏情况下的时间复杂度为  $O(n)$ 。同理，在删除和查找时，也有可能线性探测整张散列表，才能找到要查找或者删除的数据。


对于开放寻址冲突解决方法，除了线性探测方法之外，还有另外两种比较经典的探测方法，**二次探测**（Quadratic probing）和**双重散列**（Double hashing）。

所谓二次探测，跟线性探测很像，线性探测每次探测的步长是 1，那它探测的下标序列就是  $hash(key)+0$ ， $hash(key)+1$ ， $hash(key)+2$ .....而二次探测探测的步长就变成了原来的“二次方”，也就是说，它探测的下标序列就是  $hash(key)+0$ ， $hash(key)+1^2$ ， $hash(key)+2^2$ .....

所谓双重散列，意思就是不仅要使用一个散列函数。我们使用一组散列函数  $\text{hash1}(\text{key})$ ， $\text{hash2}(\text{key})$ ， $\text{hash3}(\text{key})$ .....我们先用第一个散列函数，如果计算得到的存储位置已经被占用，再用第二个散列函数，依次类推，直到找到空闲的存储位置。

不管采用哪种探测方法，当散列表中空闲位置不多的时候，散列冲突的概率就会大大提高。为了尽可能保证散列表的操作效率，一般情况下，我们会尽可能保证散列表中有一定比例的空闲槽位。我们用**装载因子**（load factor）来表示空位的多少。

装载因子的计算公式是：


 复制代码

1 散列表的装载因子 = 填入表中的元素个数 / 散列表的长度

装载因子越大，说明空闲位置越少，冲突越多，散列表的性能会下降。

## 2. 链表法

链表法是一种更加常用的散列冲突解决办法，相比开放寻址法，它要简单很多。我们来看这个图，在散列表中，每个“桶（bucket）”或者“槽（slot）”会对应一条链表，所有散列值相同的元素我们都放到相同槽位对应的链表中。





当插入的时候，我们只需要通过散列函数计算出对应的散列槽位，将其插入到对应链表中即可，所以插入的时间复杂度是  $O(1)$ 。当查找、删除一个元素时，我们同样通过散列函数计算出对应的槽，然后遍历链表查找或者删除。那查找或删除操作的时间复杂度是多少呢？

实际上，这两个操作的时间复杂度跟链表的长度  $k$  成正比，也就是  $O(k)$ 。对于散列比较均匀的散列函数来说，理论上讲， $k=n/m$ ，其中  $n$  表示散列中数据的个数， $m$  表示散列表中“槽”的个数。

## 解答开篇

有了前面这些基本知识储备，我们来看一下开篇的思考题：Word 文档中单词拼写检查功能是如何实现的？

常用的英文单词有 20 万个左右，假设单词的平均长度是 10 个字母，平均一个单词占用 10 个字节的内存空间，那 20 万英文单词大约占 2MB 的存储空间，就算放大 10 倍也就是 20MB。对于现在的计算机来说，这个大小完全可以放在内存里面。所以我们可以用散列表来存储整个英文单词词典。

当用户输入某个英文单词时，我们拿用户输入的单词去散列表中查找。如果查到，则说明拼写正确；如果没有查到，则说明拼写可能有误，给予提示。借助散列表这种数据结构，我们就可以轻松实现快速判断是否存在拼写错误。

## 内容小结

今天我讲了一些比较基础、比较偏理论的散列表知识，包括散列表的由来、散列函数、散列冲突的解决方法。

散列表来源于数组，它借助散列函数对数组这种数据结构进行扩展，利用的是数组支持按照下标随机访问元素的特性。散列表两个核心问题是**散列函数设计**和**散列冲突解决**。散列冲突有两种常用的解决方法，开放寻址法和链表法。散列函数设计的好坏决定了散列冲突的概率，也就决定散列表的性能。

针对散列函数和散列冲突，今天我只讲了一些基础的概念、方法，下一节我会更贴近实战、更加深入探讨这两个问题。

## 课后思考

1. 假设我们有 10 万条 URL 访问日志，如何按照访问次数给 URL 排序？
2. 有两个字符串数组，每个数组大约有 10 万条字符串，如何快速找出两个数组中相同的字符串？

欢迎留言和我分享，我会第一时间给你反馈。



# 数据结构与算法之美

为工程师量身打造的数据结构与算法私教课

王争

前 Google 工程师



新版升级：点击「 请朋友读」，10位好友免费读，邀请订阅更有**现金**奖励。

© 版权归极客邦科技所有，未经许可不得传播售卖。页面已增加防盗追踪，如有侵权极客邦将依法追究其法律责任。

上一篇 17 | 跳表：为什么Redis一定要用跳表来实现有序集合？

下一篇 19 | 散列表（中）：如何打造一个工业级水平的散列表？

## 精选留言 (127)

写留言



Smallfly

2018-10-31

490

1. 假设我们有 10 万条 URL 访问日志，如何按照访问次数给 URL 排序？

遍历 10 万条数据，以 URL 为 key，访问次数为 value，存入散列表，同时记录下访问次

数的最大值  $K$ ，时间复杂度  $O(N)$ 。...

展开 ▾

作者回复:  这条留言可以顶上去了 其他同学都看看吧



**K战神**

2018-11-20

 40

今天在新公司转正述职上提到了一些基础的编程原理类的学习计划。被领导和同事嗤之以鼻，现在都怀疑学习深度理论有必要么？我是一个开发6年的程序员。同事在追着最近的技术跑，而我最近阶段总觉得技术原理理论方面基础薄弱。不知道这样的坚持对不对。比如我说学习数据结构算法，他们抛开异样的眼光，觉得在说有什么用。

展开 ▾

作者回复: 你的领导 同事也有可能是水货 别局限于身边的人的观点 多上网看看大牛们都咋说



**五岳寻仙**

2018-10-31

 36

今天学习了散列表的原理，以及两种解决hash冲突的方法：开放地址法和链表法。  
课后思考题第一题，我觉得可以用hash表的链表法解决。访问次数作为slot，访问次数相同的URL放入同一个slot所对应的一条链表中，这样只需要扫一遍所有的URL就排好序了，时间复杂度为 $O(n)$

第二题跟老师讲的word拼写检查有点像，我觉得可以将一个字符串数组做成hash表，然...

展开 ▾



**姜威**

2018-10-31

 24

总结：

一、散列表的由来？

1.散列表来源于数组，它借助散列函数对数组这种数据结构进行扩展，利用的是数组支持按照下标随机访问元素的特性。

2.需要存储在散列表中的数据我们称为键，将键转化为数组下标的方法称为散列函数，散...

展开 ▾



leo  
2018-10-31

👍 23

Redis的字典是使用链式法来解决散列冲突的，并且使用了渐进式rehash的方式来进行哈希表的弹性扩容（<https://cloud.tencent.com/developer/article/1353754>，请大家斧正）。

两道思考题使用哈希表都可以解决，第二道题也可以对字符串数组进行排序后使用双指针判断，但字符串的比较成本较高，如果是整数类型更加适用。另外，哈希表比较经典的...

展开 ▾



醉比  
2018-10-31

👍 16

看到链表那一块感觉是hashmap的实现原理呀

展开 ▾



黄金的太阳  
2018-10-31

👍 15

请教老师，当我在查找元素时候，在相同散列值的链表中遍历如何区分哪个是我要找的元素？毕竟查找时查询条件只包含KEY的信息吧

展开 ▾

作者回复: 相同散列值 但是key不同的 可以再对比key



他城之途  
2018-10-31

👍 12

关于课后习题，基于某种语言的sdk实现起来可能比较容易，显然老师问的是思想，下面是我的理解，望老师和大家指正。

习题1，先分组累加次数再排序: 遍历10万数据，通过hash把相同url分组到同一个bucket下，如果bucket已存在，则取出已有次数+当前次数后再set进去，遍历完了整体再排序。

习题2，显然不是循环嵌套循环，那样时间复杂度不可接受。应该分别独立遍历两个数组...

展开 ▾



追风者  
2018-11-10

👍 11

关于100万URL排序问题？

我看了半天置顶的回答，没太明白。

url为key，出现次数count为value。数组的下标为hash(key)得到的值，保存的内容为count。

排序阶段根据count排序，不是只是改变count的位置么，对应的地址没有改变啊。...

展开 ∨



回家

2019-01-01

👍 6

假设我们有 10 万条 URL 访问日志，如何按照访问次数给 URL 排序？

1.访问次数作为key，URL和访问次数作为存储对象，存在散列表中。解决冲突的方法使用链表法，相当于实现了对URL根据访问次数进行了分组。

2.将信息存储在散列表的过程中，构造数组，数组元素是访问次数。在存入散列表的过程中，如果出现散列冲突，就不将该次数放入到数组中。...

展开 ∨




唐朝农民

2018-11-02

👍 6

Word 单词验证 是不是用 Trie 树更好，大神讲讲这个数据结构，尤其是编码这块

作者回复: 马上就要讲了 别急



万里晴空

2018-10-31

👍 6

可以写代码进行分析讲解不，这样更能感受到

展开 ∨



这么写的闫

2018-11-05


👍 5

当散列冲突，表中存储了多个相同散列值时，查询数据怎么确定查询到的是我想要的那个？

这一点很疑惑，求指点

展开 ∨

作者回复: 再全量对比 因为散列表中存储的不仅仅是哈希值 还有全量的数据信息





王荣慧

2018-11-19

4

有个疑问，如果在冲突的位置的下一个空闲位置存储数据，文中提到，根据key算出的位置存储的值和要查询的数据进行对比，确定是否是要查询的数据，如果我已经知道了要查询的数据，应该就不用查询了吧，这个地方不大理解。

展开

作者回复: 表述的不准确 我的意思是散列表中存储对象 对象包含key和附属字段 根据key构建散列表 查询的时候也是根据key 但是同一个散列值可能对应多个key 在查询的时候不能仅仅通过key的散列值 还要对比key



张三丰

2018-11-23

3

在查找的时候，一旦我们通过线性探测方法，找到一个空闲位置，我们就可以认定散列表中不存在这个数据。但是，如果这个空闲位置是我们后来删除的，就会导致原来的查找算法失效。本来存在的数据，会被认定为不存在。这个问题如何解决呢？

这句话不理解，这不正是删除的效果么。。。设置为空，下次查找的时候当然不在了啊...

展开



肖小强

2018-11-04

3

老师，关于置顶的那个回答有些疑问。

比如第一题的解答说到“url为key，出现次数为value”

我的疑问是， $\text{hash}(\text{key}) = \text{VALUE}$ ，这个VALUE经过处理后不应该是一个随机的数组的下标吗？然后把出现次数value存入到这个位置中并不断更新。我对上面那句话的理解是 $\text{hash}(\text{url}) = \text{value}$ ，所以为什么可以把出现次数作为value，value不应该是一个随机值吗...

展开

作者回复: value并不是hash函数的值。更好的表述应该是声明一个count字段



Ionizing

3



2018-11-01

个人的疑问：

1. 关于开放空间的散列冲突：既然存在散列冲突问题，插入时可以通过分配新的 key 来插入存在散列冲突的元素，那么在访问时又是如何解决散列冲突的呢？比如有两个键值对 {key1: val1}, {key2: val2} 它们的 key 在生成时是冲突的，key2 经过重新分配，现在访问 {key2: val2} 时应该如何通过hash函数得到正确的 key2 呢？假如删除 {key1: val1}，现...  
展开 ▾



吴彪

2018-10-31

👍 3

为什么数组的存储空间有限，也会加大散列冲突的概率呢？hash函数得出来的散列值相同的概率应该是很低的，比如git hash-object，几乎不可能有碰撞，为啥在散列表里碰撞的可能性就这么大

作者回复: 我们还要把散列值转化为数组下标的 单纯散列值是没法直接拿来当下标的



马小平

2018-11-07

👍 2

请教老师，当我在查找元素时候，在相同散列值的链表中遍历如何区分哪个是我要找的元素？毕竟查找时查询条件只包含KEY的信息吧

这个问题我看您回答过了今天，但是我还是没懂怎么对比Key

展开 ▾

作者回复: 散列表中存储的每个数据单元包含两部分 key和卫星数据 也就是一个对象中的其他字段。

你的问题我没太看懂 你能举个例子吗



ALAN

2018-11-02

👍 2

老师，有个问题请教下。开放寻址法查询的时候，碰到散列表为空的位置后，就不继续往后找了吗？这样设计不合理吧，因为存储的时候，存数据的散列表的位置是随机的，空的

位置后面也许存了数据呢？如果是继续找的话，那为什么删除数据后，要进行特殊标记，这样标记也没意义啊，反正碰到空的位置，还是会继续找，这样标不标记都无所谓啊？

展开 ∨